作业 2

1. 正则化的贝叶斯解释

背景: 在贝叶斯统计中,几乎每个量都是随机变量,可以是已观测的或未观测的。例如,参数 θ 通常是未观测的随机变量,而数据 x 和 y 则是观测到的随机变量。所有随机变量的联合分布也被称为模型(例如, $p(x,y,\theta)$)。每个未知量都可以通过将模型对所有观测量进行条件化来估计。这样的对未观测随机变量进行条件化的分布称为后验分布。例如在机器学习上下文中, $p(\theta \mid x,y)$ 就是后验分布。这种方法的一个结果是我们需要为模型参数赋予先验分布,即 $p(\theta)$ 。先验概率是在看到数据之前赋予的——它们捕捉了我们在观测到任何证据之前对模型参数的先验信念。

在最纯粹的贝叶斯解释中,我们需要一直保留参数的后验分布,直到预测为止,得到后验预测分布,最终的预测将是后验预测分布的期望值。然而在大多数情况下,这在计算上非常昂贵,我们会妥协,选择一种在贝叶斯意义上不那么纯粹的方法。

这种妥协是估计参数的点值(而不是完整的分布),即后验分布的众数。估计后验分布的众数也称为最大后验估计(MAP)。即:

$$\theta_{\text{MAP}} = \underset{\theta}{\operatorname{arg\,max}} \ p(\theta \mid x, y)\Theta$$

将其与之前我们见过的最大似然估计(MLE)进行比较:

$$\theta_{\text{MLE}} = \underset{\theta}{\operatorname{arg\,max}} \ p(y \mid x, \theta)\Theta$$

在这个问题中,我们探讨 MAP 估计与常见的正则化技术(这些技术应用于 MLE 估计)之间的 联系。特别地,你将证明如何选择 θ 的先验分布(例如,高斯先验或拉普拉斯先验)与不同种类 的正则化(例如, L_2 或 L_1 正则化)是等价的。你还将在第(d)部分探讨正则化强度如何影响 泛化。

(a)

如果我们假设 $p(\theta)=p(\theta\mid x)$,请证明 $\theta_{\text{MAP}}=\arg\max_{\theta}\,p(y\mid x,\theta)p(\theta)$ 。对于线性回归等不显式建模输入 x 的模型,假设 $p(\theta)=p(\theta\mid x)$ 是合理的。(请注意,这意味着 x 与 θ 在边际上独立,但在给定 y 的情况下并不条件独立。)

(b)

回顾一下, L_2 正则化在最小化损失时对参数的 L_2 范数进行惩罚(即,在概率模型中为负对数似然)。现在我们将证明,带零均值高斯先验的 MAP 估计,特别是 $\theta \sim \mathcal{N}(0,\eta^2 I)$,等价于

MLE 估计中的 L_2 正则化。具体地,证明对于某个标量 λ ,

$$\theta_{\text{MAP}} = \underset{\theta}{\text{arg min}} \ -\log p(y \mid x, \theta) + \lambda \|\theta\|_2^2 \Theta$$

另外, λ 的值是什么?

(c)

现在考虑一个具体的例子,一个线性回归模型由 $y = \theta^T x + \epsilon$ 给出,其中 $\epsilon \sim \mathcal{N}(0, \sigma^2)$ 。假设随机噪声 $\epsilon^{(i)}$ 对于每个训练样本 $x^{(i)}$ 是独立的。和之前一样,假设这个模型有一个高斯先验分布,即 $\theta \sim \mathcal{N}(0, \eta^2 I)$ 。为了方便表示,设 X 是所有训练样本输入的设计矩阵,每一行向量是一个样本输入, \vec{y} 是所有样本输出的列向量。请给出 θ_{MAP} 的闭式表达式。

(d)

接下来,考虑拉普拉斯分布,其密度函数为

$$f_L(z \mid \mu, b) = \frac{1}{2b} \exp\left(-\frac{|z - \mu|}{b}\right) \Theta$$

和之前一样,考虑线性回归模型 $y=x^T\theta+\epsilon$,其中 $\epsilon\sim\mathcal{N}(0,\sigma^2)$ 。假设该模型的每个参数 θ_i 都是边际独立的,且 $\theta_i\sim\mathcal{L}(0,b)$ 。证明此时的 θ_{MAP} 等价于带 L_1 正则化的线性回归的解,其损失函数定义为

$$J(\theta) = \|X\theta - \vec{y}\|_2^2 + \gamma \|\theta\|_1 \Theta$$

另外, γ 的值是什么?

注意: 带 L_1 正则化的线性回归问题并不存在闭式解。为了优化它,我们使用随机初始化的 梯度下降法,进行数值求解。

备注: 带 L_2 正则化的线性回归也被称为岭回归(Ridge regression),而带 L_1 正则化的情况则通常被称为套索回归(Lasso regression)。这些正则化方法同样可以应用于任意广义线性模型,正如上面所示(通过将 $\log p(y \mid x, \theta)$ 替换为相应的族似然)。上述类型的正则化技术也称为权重衰减和收缩。高斯和拉普拉斯先验鼓励参数值更接近于它们的均值(即零),这导致了收缩效应。

备注: 套索回归(即 L_1 正则化)通常会导致稀疏参数,其中大多数参数值为零,只有一部分参数值非零。

2. 逻辑回归: 训练稳定性

在这个问题中,我们将深入研究逻辑回归的工作机制。考虑一个二分类问题,其中数据点为 $(x^{(i)}, y^{(i)}), x^{(i)} \in \mathbb{R}^d, y^{(i)} \in \{0, 1\}$ 。我们使用逻辑回归模型正类的概率:

$$P(y=1|x^{(i)}) = \frac{1}{1+e^{-\theta^T x^{(i)}}}$$
fi

其中 $\theta \in \mathbb{R}^d$ 是参数向量。

逻辑回归的**损失函数**(也称为交叉熵损失)对于 n 个数据点的定义为:

$$L(\theta) = -\sum_{i=1}^{n} \left(y^{(i)} \log(P(y=1|x^{(i)})) + (1-y^{(i)}) \log(1-P(y=1|x^{(i)})) \right) \Theta$$

假设 John 实现了逻辑回归,并在两个标注数据集上进行训练:

- 数据集 A: 一个不可分的数据集,其中不存在一个超平面能够完全分开这两个类。换句话说,对于任何参数向量 θ 的选择,总有一些来自每个类的点位于由 $\theta^T x = 0$ 定义的超平面的两侧。
- 数据集 B: 一个可分的数据集,其中存在一个超平面可以完全分开这两个类,也就是说,存在一个参数向量 θ ,使得所有正例 ($y^{(i)}=1$) 位于超平面的同一侧,而所有负例 ($y^{(i)}=0$) 位于另一侧。

训练后, John 观察到他的模型在数据集 A 上收敛, 但在数据集 B 上未能收敛。他想了解原因。你的任务是帮助他分析这一现象。

(a)

假设我们用 $c \cdot \theta$ 来替换 θ ,其中 c > 0 是一个常数。证明当 $c \to \infty$ 时,对于正确分类的样本,正例的预测概率趋于 1,负例的预测概率趋于 0。

(b)

利用第 (a) 部分的结果,证明在线性可分的数据中,损失函数 $L(\theta)$ 随着 $c \to \infty$ 而无限下降。解释为什么这意味着梯度下降在这种情况下会失败而无法收敛。

(c)

将此与不可分数据的情况进行对比。解释为什么在不可分的情况下损失函数有一个有限的下 界,并且梯度下降能够收敛。

(d)

对于以下每个修改,说明它是否会导致训练算法在像 B 这样的数据集上收敛。

- 使用不同的常数学习率。
- 随时间减少学习率(例如,随着梯度下降迭代次数 t 增加,初始学习率按 1/t² 缩放)。
- 对输入特征应用线性缩放。
- 在损失函数中添加正则项 $\|\theta\|^2$ 。
- 在训练数据或标签上添加零均值高斯噪声。

在接下来的问题中,我们考虑具有多层的神经网络。每一层有多个输入和输出,并可以分为两个部分:

- 一个线性模块,它实现线性变换: $z_j = (\sum_{i=1}^m x_i w_{i,j}) + w_{0,j}$,由权重矩阵 W 和偏置向量 W_0 指定。输出为 $[z_1, \ldots, z_n]^T$ 。
- 一个激活模块,它对线性模块的输出应用激活函数,例如在隐藏层中使用 Tanh 或 ReLU 激活函数,或在输出层使用 Softmax(见下文)。我们将输出表示为 $[f(z_1),\ldots,f(z_m)]^T$,尽管技术上来说,对于某些激活函数(如 softmax),每个输出将依赖于所有 z_i ,而不仅仅是一个。

我们将使用以下符号来表示网络中的量:

- 网络的输入为 x_1, \ldots, x_d 。
- 長数为 L。
- 第 l 层有 m^l 个输入。
- 第 l 层有 $n^l = m^l + 1$ 个输出。
- 第 l 层的权重矩阵为 W^l ,是一个 $m^l \times n^l$ 的矩阵,偏置向量(偏移)为 W_0^l ,是一个 $n^l \times 1$ 的向量。
- 第 l 层线性模块的输出称为**预激活**值,记作 z^l 。
- 第 l 层的激活函数为 $f^l(\cdot)$ 。
- 第 l 层的激活值为 $a^l = [f^l(z_1^l), \dots, f^l(z_{n_l}^l)]^T$.
- 网络的输出是 $a^L = \left[f^L(z_1^L), \dots, f^L(z_{n_r}^L)\right]^T$ 。
- 损失函数 Loss(a, y) 用于度量输出值 a 在目标为 y 时的损失。

3. 多分类问题

如果我们需要将作业题目分类为三类:有趣的、无聊的和不可能完成的,我们可以在输出上使用独热编码,并使用三个输出单元以及称为softmax(SM)的激活模块。它不是一个典型的激活模块,因为它接受所有 n_L 个预激活值 $z_j^L \in \mathbb{R}$,并返回 n_L 个输出值 $a_j^L \in [0,1]$,使得 $\sum_i a_i^L = 1$ 。这可以被解释为对可能类别的概率分布。

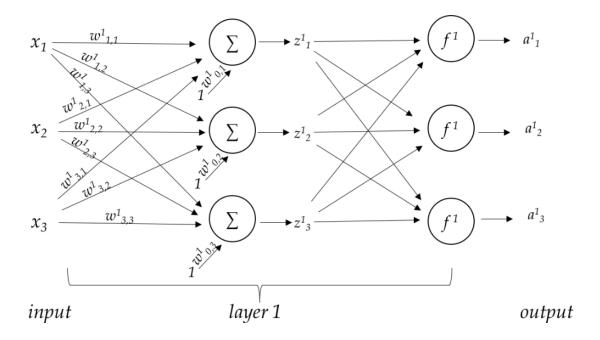
个别条目计算如下:

$$a_j = \frac{e^{z_j}}{\sum_{k=1}^{n_L} e^{z_k}}$$

我们将向量 a 与向量 z 的关系描述为

$$\mathbf{a} = SM(\mathbf{z})$$

下图显示了一个由线性模块和 softmax 激活模块组成的单层网络。



(a)

由 $z_L = [-1, 0, 1]^T$ 表示的类别概率分布是什么?

(b)

现在,我们需要一个损失函数 $Loss(\mathbf{a}, \mathbf{y})$,其中 \mathbf{a} 是离散概率分布, \mathbf{y} 是一个单输出值的独 热向量编码。由于与之前相同的原因,使用负对数似然作为损失函数是有意义的。因此,我们将 之前的 NLL 定义扩展为:

$$NLL(\mathbf{a}, \mathbf{y}) = -\sum_{i=1}^{n_L} y_i \ln a_j^L \Theta$$

注意,上述表达式适用于多类(类别数 > 2)的情况。 如果 $\mathbf{a} = [0.3, 0.5, 0.2]^T$ 且 $\mathbf{y} = [0, 0, 1]^T$,那么 $NLL(\mathbf{a}, \mathbf{y})$ 是多少?

(c)

现在,我们可以考虑一个带有 softmax 激活模块的单层,训练目标是最小化 NLL。预激活值(线性模块的输出)为:

$$z_{j}^{L} = \sum_{k} w_{k,j}^{L} x_{k} + w_{0,j}^{L}$$

为了进行梯度下降,我们需要知道 $\frac{\partial}{\partial w_{k,j}^L} NLL(a^L, \mathbf{y})$ 。尝试证明

$$\frac{\partial}{\partial w_{k,j}^L} NLL(a^L, \mathbf{y}) = x_k (a_j^L - y_j)$$

当然,可以通过一次快速矩阵计算来计算这些导数的整个矩阵,即 $\nabla_{W^L} NLL(a^L, \mathbf{y})$ 。

假设我们有两个输入单元和三个可能的输出值,权重矩阵 W^L 为

$$W^L = \begin{bmatrix} 1 & -1 & -2 \\ -1 & 2 & 1 \end{bmatrix}$$

假设偏置为零,输入 $\mathbf{x}=[1,1]^T$,目标输出 $\mathbf{y}=[0,1,0]^T$ 。那么矩阵 $\nabla_{W^L}NLL(a^L,\mathbf{y})$ 是多少?

(d)

在进行任何梯度更新之前, x 属于类别 1 的预测概率是多少?(假设我们有类别 0、1 和 2。)

(e)

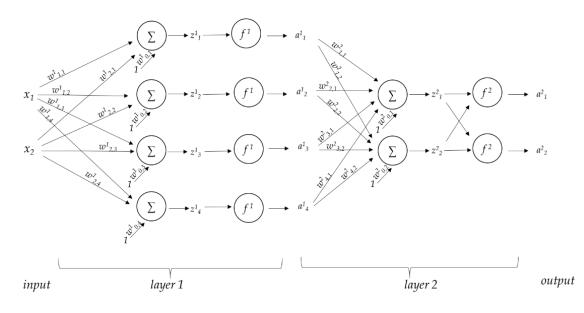
使用步长 0.5, 经过一次梯度更新后, W^L 是多少?

(f)

给定新的权重矩阵, x 属于类别 1 的预测概率是多少?

4. 神经网络

考虑下图所示的神经网络,其中所有隐藏神经元都使用 ReLU 激活函数(图中的 f^1),输出 层使用 softmax 激活函数(图中的 f^2),输出为 softmax 输出(图中的 a_1^2 和 a_2^2)。



给定输入 $\mathbf{x} = [x_1, x_2]^T$, 网络的隐藏单元按以下方程分阶段激活:

$$z_{1}^{1} = x_{1}w_{1,1}^{1} + x_{2}w_{2,1}^{1} + w_{0,1}^{1}$$

$$a_{1}^{1} = \max\{z_{1}^{1}, 0\}$$

$$z_{2}^{1} = x_{1}w_{1,2}^{1} + x_{2}w_{2,2}^{1} + w_{0,2}^{1}$$

$$a_{2}^{1} = \max\{z_{2}^{1}, 0\}$$

$$z_{3}^{1} = x_{1}w_{1,3}^{1} + x_{2}w_{2,3}^{1} + w_{0,3}^{1}$$

$$a_{3}^{1} = \max\{z_{3}^{1}, 0\}$$

$$z_{4}^{1} = x_{1}w_{1,4}^{1} + x_{2}w_{2,4}^{1} + w_{0,4}^{1}$$

$$a_{4}^{1} = \max\{z_{4}^{1}, 0\}$$

$$\begin{split} z_1^2 &= a_1^1 w_{1,1}^2 + a_2^1 w_{2,1}^2 + a_3^1 w_{3,1}^2 + a_4^1 w_{4,1}^2 + w_{0,1}^2 \\ z_2^2 &= a_1^1 w_{1,2}^2 + a_2^1 w_{2,2}^2 + a_3^1 w_{3,2}^2 + a_4^1 w_{4,2}^2 + w_{0,2}^2 \end{split}$$

网络的最终输出通过对最后一层应用 softmax 函数得到:

$$a_1^2 = \frac{e^{z_1^2}}{e^{z_1^2} + e^{z_2^2}}$$
$$a_2^2 = \frac{e^{z_2^2}}{e^{z_1^2} + e^{z_2^2}}$$

在这个问题中,我们将考虑以下参数设置:

$$\begin{bmatrix} w_{1,1}^1 & w_{1,2}^1 & w_{1,3}^1 & w_{1,4}^1 \\ w_{2,1}^1 & w_{2,2}^1 & w_{2,3}^1 & w_{2,4}^1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & -1 & 0 \\ 0 & 1 & 0 & -1 \end{bmatrix}, \qquad \begin{bmatrix} w_{0,1}^1 \\ w_{0,2}^1 \\ w_{0,3}^1 \\ w_{0,4}^1 \end{bmatrix} = \begin{bmatrix} -1 \\ -1 \\ -1 \\ -1 \end{bmatrix},$$

$$\begin{bmatrix} w_{1,1}^2 & w_{1,2}^2 \\ w_{2,1}^2 & w_{2,2}^2 \\ w_{3,1}^2 & w_{3,2}^2 \\ w_{4,1}^2 & w_{4,2}^2 \end{bmatrix} = \begin{bmatrix} 1 & -1 \\ 1 & -1 \\ 1 & -1 \\ 1 & -1 \end{bmatrix},$$

$$\begin{bmatrix} w_{0,1}^2 \\ w_{0,2}^2 \end{bmatrix} = \begin{bmatrix} 0 \\ 2 \end{bmatrix}$$

(a)

考虑输入 $x_1 = 3, x_2 = 14$ 。 网络隐藏单元的输出 $(f^1(z_1^1), f^1(z_2^1), f^1(z_3^1), f^1(z_4^1))$ 和最终输出 (a_1^2, a_2^2) 是什么?

(b)

考虑以下输入向量: $x^{(1)} = [0.5, 0.5]^T$, $x^{(2)} = [0, 2]^T$, $x^{(3)} = [-3, 0.5]^T$ 。输入一个矩阵,其中每一列表示每个输入向量的隐藏单元的输出 $(f(z_1^1), \ldots, f(z_4^1))$ 。

(c)

在上面的网络中,输出层有两个 softmax 单元,用于分类为两个类之一。对于第一个类,第一个单元的输出应大于另一个单元的输出;对于第二个类,第二个单元的输出应大于第一个单元的输出。这可以通过使用 k 个输出单元自然地扩展到 k 个类。

下面描述网络输出表示第一个类(即 a_1^2 较大)或第二个类(即 a_2^2 较大)在 x 空间中的区域。

神经网络在以下情况下的输出值是什么?

情况 1)
$$f(z_1^1) + f(z_2^1) + f(z_3^1) + f(z_4^1) = 0$$

情况 2)
$$f(z_1^1) + f(z_2^1) + f(z_3^1) + f(z_4^1) = 1$$

情况 3)
$$f(z_1^1) + f(z_2^1) + f(z_3^1) + f(z_4^1) = 3$$

(d)

使用交叉熵损失函数(Cross-Entropy Loss),给定输入样本 $(x_1=3,x_2=14)$ 和目标向量 $(y_1,y_2)=(0,1)$,执行一次反向传播步骤,以学习率 $\eta=0.1$ 更新网络中的每一个权重。